INSA INSTITUT NATIONAL DES SCIENCES APPLIQUÉES TOULOUSE

TP 1 : Analyse exploratoire de données

Alice Grenier-Dekeuwer, 5SDBD

30 octobre 2026

Table des matières

Introduction **2**

1 Compréhension du jeu de données **2**

2 Analyse d'une problématique **2**
2.1 Formulation de la problématique 2
2.2 Analyse des données 2
2.2.1 Etude de la distribution de la variable cible 2
2.2.2 L'impact de l'âge sur l'évolution salariale 3
2.2.3 L'impact du niveau de diplôme sur le revenu 4
2.2.4 Disparités de genre 4
2.2.5 Vérification des redondances 5

Conclusion **5**

Introduction

Dans le cadre de ce TP, nous nous intéressons à la problématique de la prédiction de revenus à partir de données socio-démographiques. Le jeu de données utilisé est ACISIncome pour l'état de Californie. La tâche est une classification binaire : prédire si le revenu annuel d'un individu actif est supérieur à 50 000 dollars. Le présent rapport permet de rendre compte des expérimentations effectuées.

1 Compréhension du jeu de données

Le jeu de données comprend des exemples, correspondant chacun à un individu travaillant dans l'état de Californie. Chaque exemple est défini par 10 attributs, exposés dans la table ci-dessous.

Table 1 – Description des attributs du jeu de données ACSIncome

Attribut	**Description**
AGEP	Âge de l'individu (>16)
COW	Classe de travailleur (1 - salarié privé, 4 - fonctionnaire d'Etat, 9 - chômage...)
SCHL	Niveau d'éducation (de la maternelle au doctorat, 24 niveaux)
MAR	Statut marital (1 - marié, 2 - veuf, 3 - divorcé...)
OCCP	Code de profession (nomenclature ACS PUMS)
POBP	Lieu de naissance (pays ou état américain)
RELP	Relation (père/mère, conjoint, enfant...)
WKHP	Heures travaillées par semaine (>0)
SEX	Sexe (1 = Homme, 2 = Femme)
RAC1P	Race (9 catégories : blanc, noir, asiatique...)

L'analyse préliminaire du jeu de données permet par ailleurs les observations suivantes :
— Il y a 166315 individus californiens.
— Il y a 123 261 individus de plus de 30 ans.

	AGEP	COW	SCHL	MAR	OCCP	POBP	RELP	WKHP	SEX	RAC1P
0	41.0	4.0	24.0	1.0	2555.0	6.0	1.0	60.0	2.0	1.0
1	77.0	7.0	22.0	1.0	4920.0	39.0	0.0	35.0	1.0	1.0
2	38.0	1.0	18.0	1.0	440.0	6.0	1.0	50.0	1.0	1.0
4	36.0	1.0	16.0	1.0	4030.0	314.0	1.0	70.0	2.0	1.0
9	34.0	3.0	21.0	1.0	2310.0	6.0	0.0	40.0	2.0	1.0

Figure 1 – Aperçu des premiers individus de plus de 30 ans mariés

2 Analyse d'une problématique

2.1 Formulation de la problématique

L'objectif de l'étude est de répondre à la problématique suivante : *Dans quelle mesure les caractéristiques démographiques et les choix professionnels influencent-ils la le revenu annuel d'un travailleur californien ?*

L'objectif de cette approche est de comprendre les leviers de la performance économique au sein de cet état, et de mettre en lumière des biais algorithmiques et sociétaux (notamment ceux liés au genre).

2.2 Analyse des données

2.2.1 Etude de la distribution de la variable cible

Tout d'abord, la Figure 2 permet d'analyser la distribution de la variable cible (`PINCP`), qui indique si le revenu est supérieur (1) ou inférieur (0) à 50 000 USD. Le graphique montre un déséquilibre des

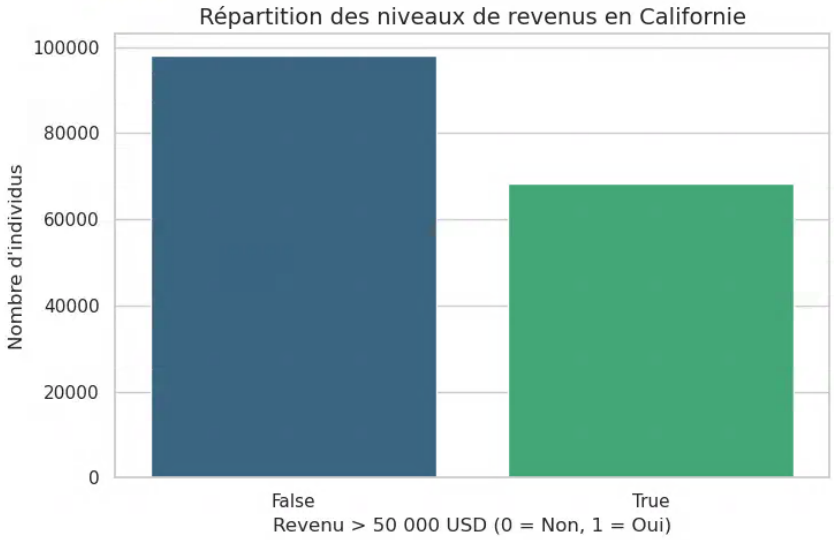


FIGURE 2 – Distribution de la variable cible (le revenu)

classes au sein de la population californienne étudiée ; la classe majoritaire est celle des individus gagnant moins de 50 000 USD par an.

2.2.2 L'impact de l'âge sur l'évolution salariale

L'âge (`AGEP`) étant un indicateur de l'expérience professionnelle accumulée, il convient ensuite de croiser cette variable avec la variable cible.

La Figure 3 montre que la médiane d'âge des travailleurs gagnant plus de 50 000 USD est plus élevée (autour de 45 ans) que celle de la classe inférieure (autour de 35 ans). Le premier quartile de la classe des hauts revenus démarre au-dessus de celui des bas revenus, ce qui illustre la logique de progression salariale au fil de la carrière. On note cependant des valeurs extrêmes : des jeunes parvenant très tôt à de hauts revenus, et des travailleurs âgés n'ayant pas franchi ce cap. L'âge est donc un prédicteur pertinent mais ne se suffit pas à lui-même.

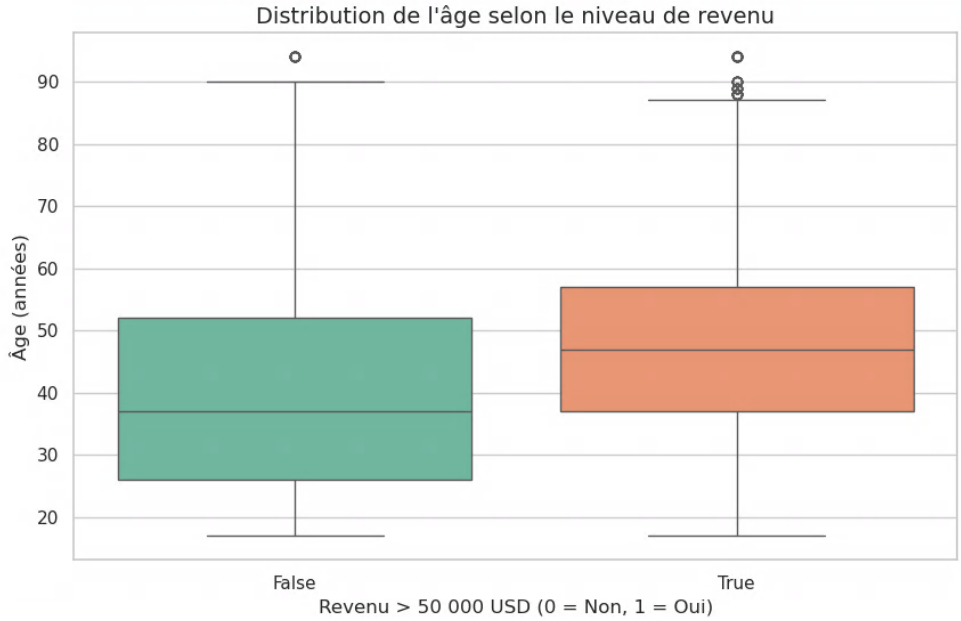


FIGURE 3 – Distribution de l'âge selon le niveau de revenu

2.2.3 L'impact du niveau de diplôme sur le revenu

L'analyse de la variable `SCHL` (*Educational attainment*) est ensuite restreinte à quatre paliers : High School, Bachelor, Master et Doctorate.

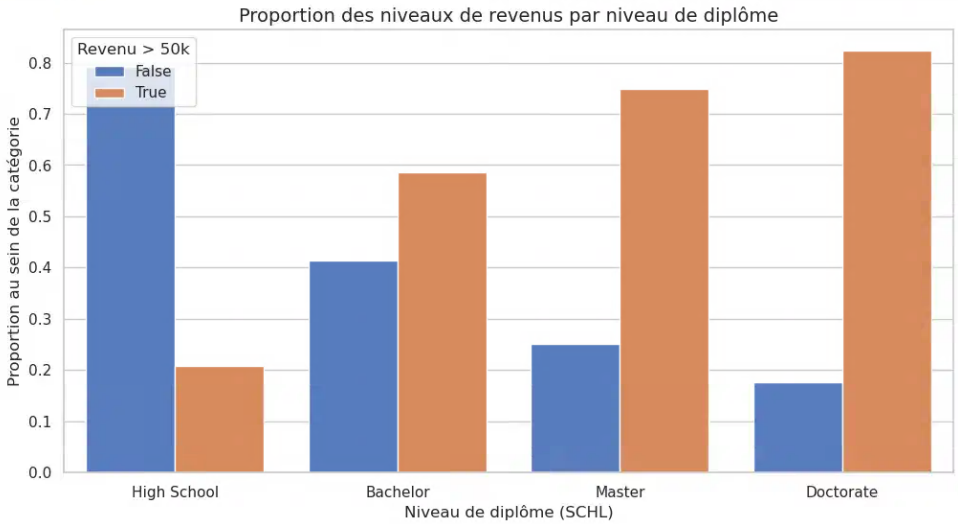


FIGURE 4 – Proportion des niveaux de revenus par niveau de diplôme

La Figure 4 montre une corrélation croissante entre le niveau de diplôme et la probabilité d'appartenir à la classe des hauts revenus. La grande majorité des détenteurs d'un diplôme d'études secondaires gagnent moins de 50 000 USD. À l'inverse, les individus ayant obtenu un Master ou un Doctorat gagne majoritairement plus de 50 000 USD. Le diplôme est donc un attribut discriminant pour différencier les classes.

2.2.4 Disparités de genre

Dans la perspective d'étudier l'équité des futurs modèles de Machine Learning, le sexe (`SEX`) est croisé avec le volume horaire hebdomadaire (`WKHP`) et le revenu.

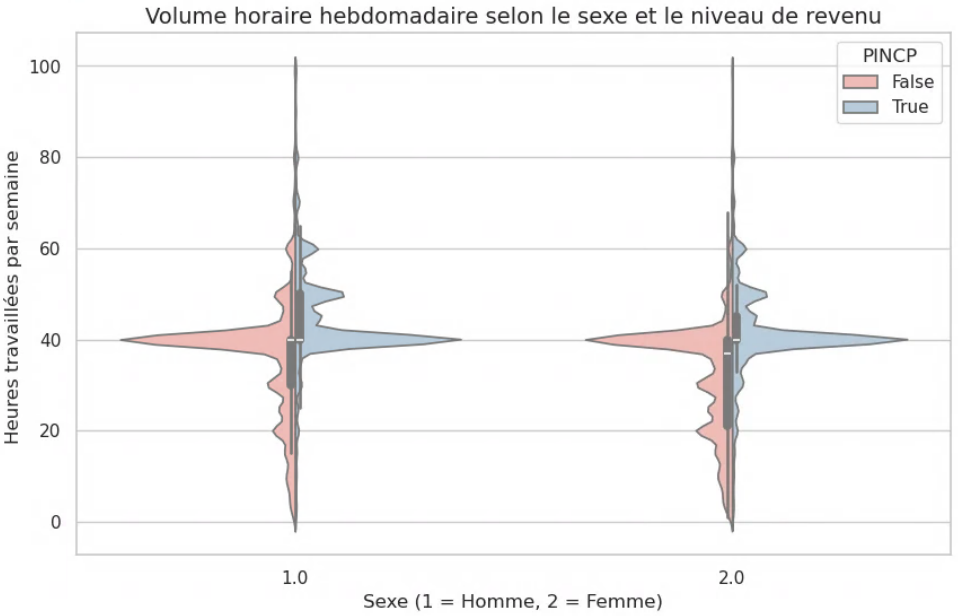


FIGURE 5 – Volume horaire hebdomadaire selon le sexe et le niveau de revenu

La Figure 5 indique que pour les hommes comme pour les femmes, le pic de densité (le mode) se situe autour de 40 heures hebdomadaires, ce qui correspond au temps plein standard aux Etats-Unis. Toutefois, pour franchir le seuil des 50 000 USD, la distribution s'étire fortement vers le haut (50 heures et plus) chez les hommes, de manière beaucoup plus prononcée que chez les femmes. Ce phénomène traduit une disparité de genre sur le marché du travail : les femmes à haut revenu travaillent un nombre d'heures plus resserré autour de 40h, tandis que les hommes hauts revenus accumulent davantage d'heures supplémentaires.

2.2.5 Vérification des redondances

Pour terminer, on vérifie que nos variables prédictives quantitatives ne sont pas redondantes.

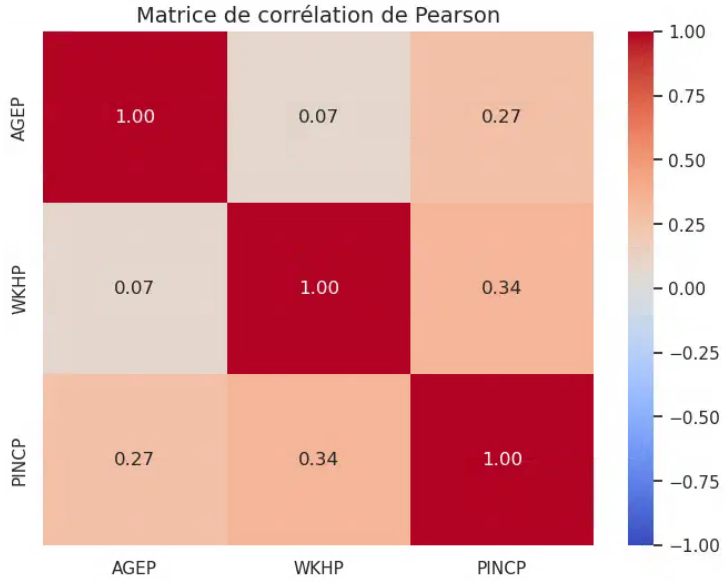


FIGURE 6 – Matrice de corrélation de Pearson

La Figure 6 met en évidence des corrélations positives modérées entre le fait d'avoir un haut revenu, l'âge et le temps de travail. Cela signifie que les variables ne sont pas redondantes entre elles.

Conclusion

L'analyse exploratoire a permis de mettre en évidence les indicateurs pertinents pour la caractérisation du marché de l'emploi californien. L'âge, l'éducation et le volume horaire sont des facteurs déterminants pour atteindre un haut revenu, mais la répartition des données montre des déséquilibres (classes inégales) et des biais sociétaux (inégalités structurelles liées au sexe).